

Introducción a la Inteligencia Artificial

Clase 4



Índice

1. Trabajar sobre notebook de clase 3
2. Análisis de la regresión lineal (R^2)
3. Descomposición Bias-Variance
4. Notebooks clase 4
5. Ejercicios clase 4

Coeficiente de determinación - “R cuadrado”


$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

SS = Sum of squares

res = residuos

tot = total

Regresión Lineal - R2



$$SS_{reg} = \sum_i (f_i - \bar{y})^2$$

$$SS_{res} = \sum_i (y_i - f_i)^2 = \sum_i e_i^2$$

$$SS_{tot} = \sum_i (y_i - \bar{y})^2$$
$$= SS_{res} + SS_{reg}$$

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

$r_i = y_i - \hat{y}_i$
↳ *residuo*

¿Similar a σ^2 ?


Regresión Lineal - R2

$$\begin{aligned} R^2 &= 1 - \frac{SS_{res}}{SS_{tot}} \\ &= 1 - \left(\frac{SS_{res}}{SS_{tot}} * \frac{n}{n} \right) \\ &= 1 - \frac{\sigma_{res}}{\sigma_{tot}} \end{aligned}$$

Proporción de varianza no explicada

Proporción de varianza explicada

• Analizamos inicialmente la regresión **simple**:



partimos de $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

definimos el i -ésimo residuo como

$$r_i = y_i - \hat{y}_i$$

$$(\hat{\beta}_0, \hat{\beta}_1) = \underset{f}{\operatorname{argmin}} \underbrace{\sum_i (y_i - \beta_0 - \beta_1 x_i)^2}_{f} \leadsto \min \sum_i r_i^2$$

$$\begin{cases} \partial_{\beta_0} f = 0 \rightarrow -2 \sum_i (y_i - \beta_0 - \beta_1 x_i) \rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \partial_{\beta_1} f = 0 \rightarrow -2 \sum_i (y_i - \beta_0 - \beta_1 x_i) x_i \rightarrow \hat{\beta}_1 = \frac{\frac{1}{N} \sum_i (x_i - \bar{x})(y_i - \bar{y})^2}{\frac{1}{N} \sum_i (x_i - \bar{x})^2} \end{cases}$$

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{\widehat{\operatorname{cov}}(x, y)}{\widehat{\operatorname{var}}(x)} = \hat{\rho}_{x, y} \rightarrow \text{Coeficiente de correlación de Pearson} \end{cases}$$

Vamos a analizar los errores:

$$y_i = \hat{y}_i + r_i$$

↓ sumamos $-\bar{y}$ a ambos lados

$$y_i - \bar{y} = \hat{y}_i - \bar{y} + r_i \quad \Rightarrow \quad \underbrace{\sum_{i=0}^N (y_i - \bar{y})^2}_{\text{TSS}} = \underbrace{\sum_{i=0}^N (\hat{y}_i - \bar{y})^2}_{\text{ESS}} + \underbrace{\sum_{i=0}^N r_i^2}_{\text{RSS}}$$

TSS
Tasa de
Variabilidad
total

ESS
tasa de
Variabilidad
explicada

RSS
↓
suma de
residuos al
cuadrado

Con TSS, ESS y RSS puedo construir: métricas, índices
de bondad de ajuste o análisis de regresión avanzada

con esto ¿Cómo sabemos si el modelo es bueno?

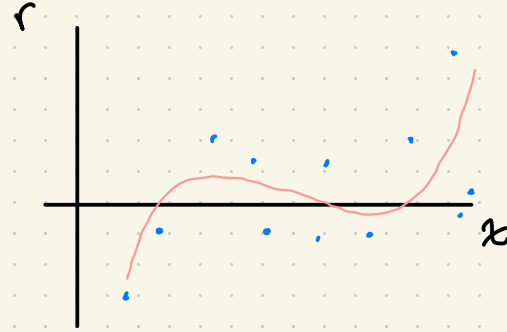


→ Error residual (RSE)

→ Estadístico F

→ est. R^2 (coef. de Pearson, R^2)

$$+ RSE = \sqrt{\frac{RSS}{N-2}} = \frac{1}{N-2} \sqrt{\sum_{i=0}^N (y_i - \hat{y}_i)^2}$$

si $RSE \downarrow \Rightarrow$ mi ajuste es bueno



RSE no es sensible a la distrib. de r




+ $R^2 \rightarrow$ mide la bondad del ajuste
 \hookrightarrow equivalente al coef. de correlación al cuadrado:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} = \hat{\beta}_{xy}^2 \quad (\text{esto en regresión lineal simple})$$

$\Rightarrow R^2$ *no depende* de las escalas (unidades) de y , solo de las proporciones

$\Rightarrow R^2 \in [0, 1] \rightarrow R^2 \sim 1 \Rightarrow$ el modelo es "bueno"

$R^2 \leq 0 \Rightarrow$ el modelo es peor que estimar con la media.



$$\beta_0 \sim 3, \beta_1 \sim 0,5 \Rightarrow R^2 = 0,7$$

• Estadístico F:

Voy a armar una tabla ANOVA del ajuste:

Fuentes de variación	SS	gl	cuad. medios
Explicada (ESS)	$\sum_i (\hat{y}_i - \bar{y})^2$	1	$\sum_i (\hat{y}_i - \bar{y})^2$
Residual (RSS)	$\sum r_i^2$	$n-2$	$S_R = \frac{1}{n-2} \sum_i r_i^2$
total (TSS)	$\sum_i (y_i - \bar{y})^2$	$n-1$	

construimos $F = \frac{ESS}{S_R^2} \rightarrow$ si $F \uparrow \Rightarrow$ la variabilidad explicada es muy grande respecto a la no explicada

Planteamos el sig. test de hipótesis:

$$TH: \begin{cases} H_0: \beta_1 = 0 \\ H_1: \beta_1 \neq 0 \end{cases} \Rightarrow P(F \geq f_{\alpha, 1, n-2})$$

\nearrow
 $f_{1, n-2, 1-\alpha}$

¿Cómo interpretamos esto?

. hipótesis nula: supone que mi OLS no es mejor que un modelo constante. no explica mejor la varianza que un modelo cte.

. hipótesis alternativa: mi modelo OLS explica mejor (es estadísticamente significativo) la varianza de la respuesta que un modelo constante.

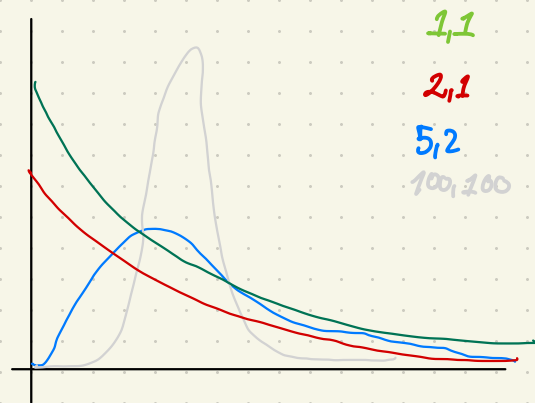
¿Cómo calculamos el F-test?

1. Armamos la tabla anova.
2. obtenemos el estadístico $F = ESS/S_r^2$
3. calculamos el p-valor, $f_{crit} \leadsto$ definimos el nivel de significancia α .


$$f \sim F_{g_{ESS}, g_{RSS}}$$

4. buscar $P(F \geq f_{crit}) = \alpha$

5. si $F > f_{crit} \Rightarrow$ rechazo H_0




Regresión Lineal - R2



$$SS(media) = (happiness - media)^2$$

$$Variación(media) = \frac{(happiness - media)^2}{n}$$

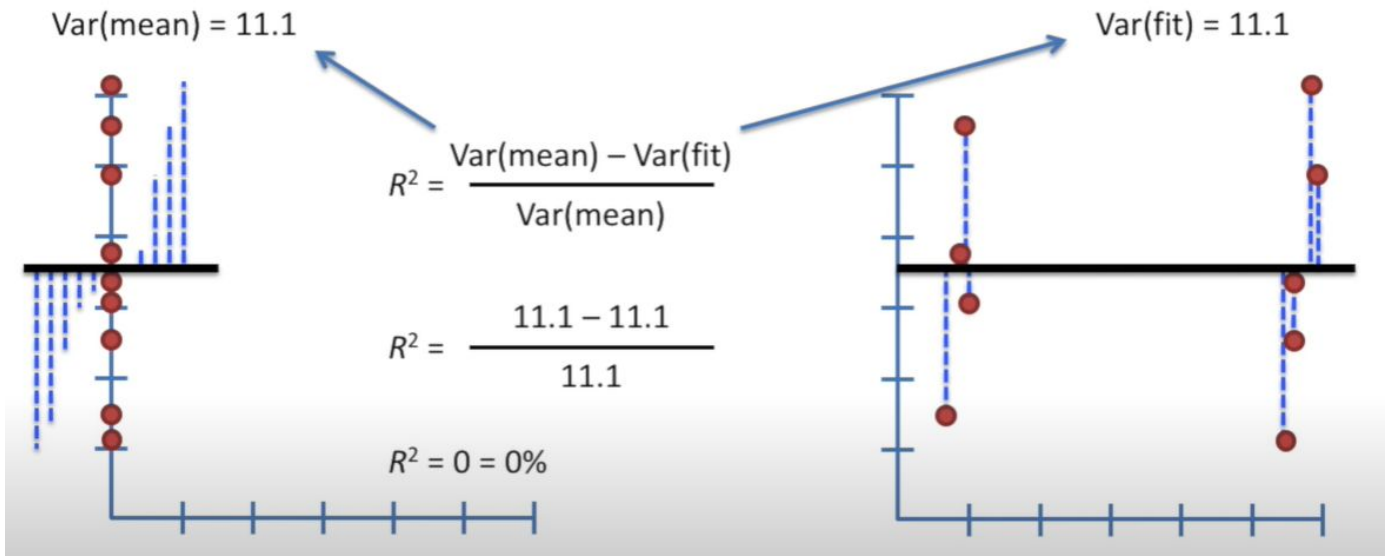


$$SS(fit) = (happiness - lr_fit)^2$$

$$Variación(fit) = \frac{(happiness - lr_fit)^2}{n}$$

Regresión Lineal - R2

$$R^2 = \frac{\text{Variación}(\text{media}) - \text{Variación}(\text{fit})}{\text{Variación}(\text{media})}$$



Fuente: StatQuest with Josh Starmer

Regresión Lineal - R2


$$F = \frac{\text{Varación en happiness explicada por income}}{\text{Variación en happiness no explicada por income}}$$

$$SS(\text{mean}) = 10$$

$$SS(\text{fit}) = 0$$

$$R^2 = \frac{SS(\text{mean}) - SS(\text{fit})}{SS(\text{mean})}$$

$$= \frac{100 - 0}{100} = 100\%$$



Fuente: StatQuest with Josh Starmer

R² y el coeficiente de correlación de Pearson


$$\rho = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} \in [-1, 1]$$

Regresión múltiple **con ordenada** → Correlación entre observación y predicción

Regresión **con ordenada** → Correlación entre variable dependiente e independiente

$$\rho^2 = R^2 \in [0, 1]$$

Coeficiente de correlación de Pearson




R2 inflation

\uparrow cantidad de predictores $\rightarrow \uparrow R^2 \rightarrow$ F-test para comparación válida entre modelos.

¿R² negativo?

$$R^2 = 1 - \frac{\sigma_{res}}{\sigma_{tot}} < 0 \Leftrightarrow \sigma_{res} > \sigma_{tot}$$



Predecir con el promedio es mejor que el modelo

Otras medidas a tener en cuenta

$$\text{MAE} = \frac{\sum_{i=1}^n |y_i - x_i|}{n} = \frac{\sum_{i=1}^n |e_i|}{n}.$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$

$$\text{RMSD} = \sqrt{\frac{\sum_{t=1}^T (\hat{y}_t - y_t)^2}{T}}.$$

Bias-Variance Tradeoff


Cuando utilizamos el **error cuadrático medio** en un modelo de ML, podemos descomponer el mismo en términos de bias (sesgo) y variance (varianza).

$$MSE = Bias(\hat{f})^2 + Var(\hat{f}) + \sigma_{\epsilon}^2$$

$$Bias = E[\hat{f} - f]$$

$$Var(\hat{f}) = E[(E[\hat{f}] - \hat{f})^2]$$

Bias-Variance Tradeoff



Bibliografía

- The Elements of Statistical Learning | Trevor Hastie | Springer
- An Introduction to Statistical Learning | Gareth James | Springer
- Deep Learning | Ian Goodfellow | <https://www.deeplearningbook.org/>
- Stanford | CS229T/STATS231: Statistical Learning Theory | <http://web.stanford.edu/class/cs229t/>
- Mathematics for Machine Learning | Deisenroth, Faisal, Ong
- Artificial Intelligence, A Modern Approach | Stuart J. Russell, Peter Norvig