

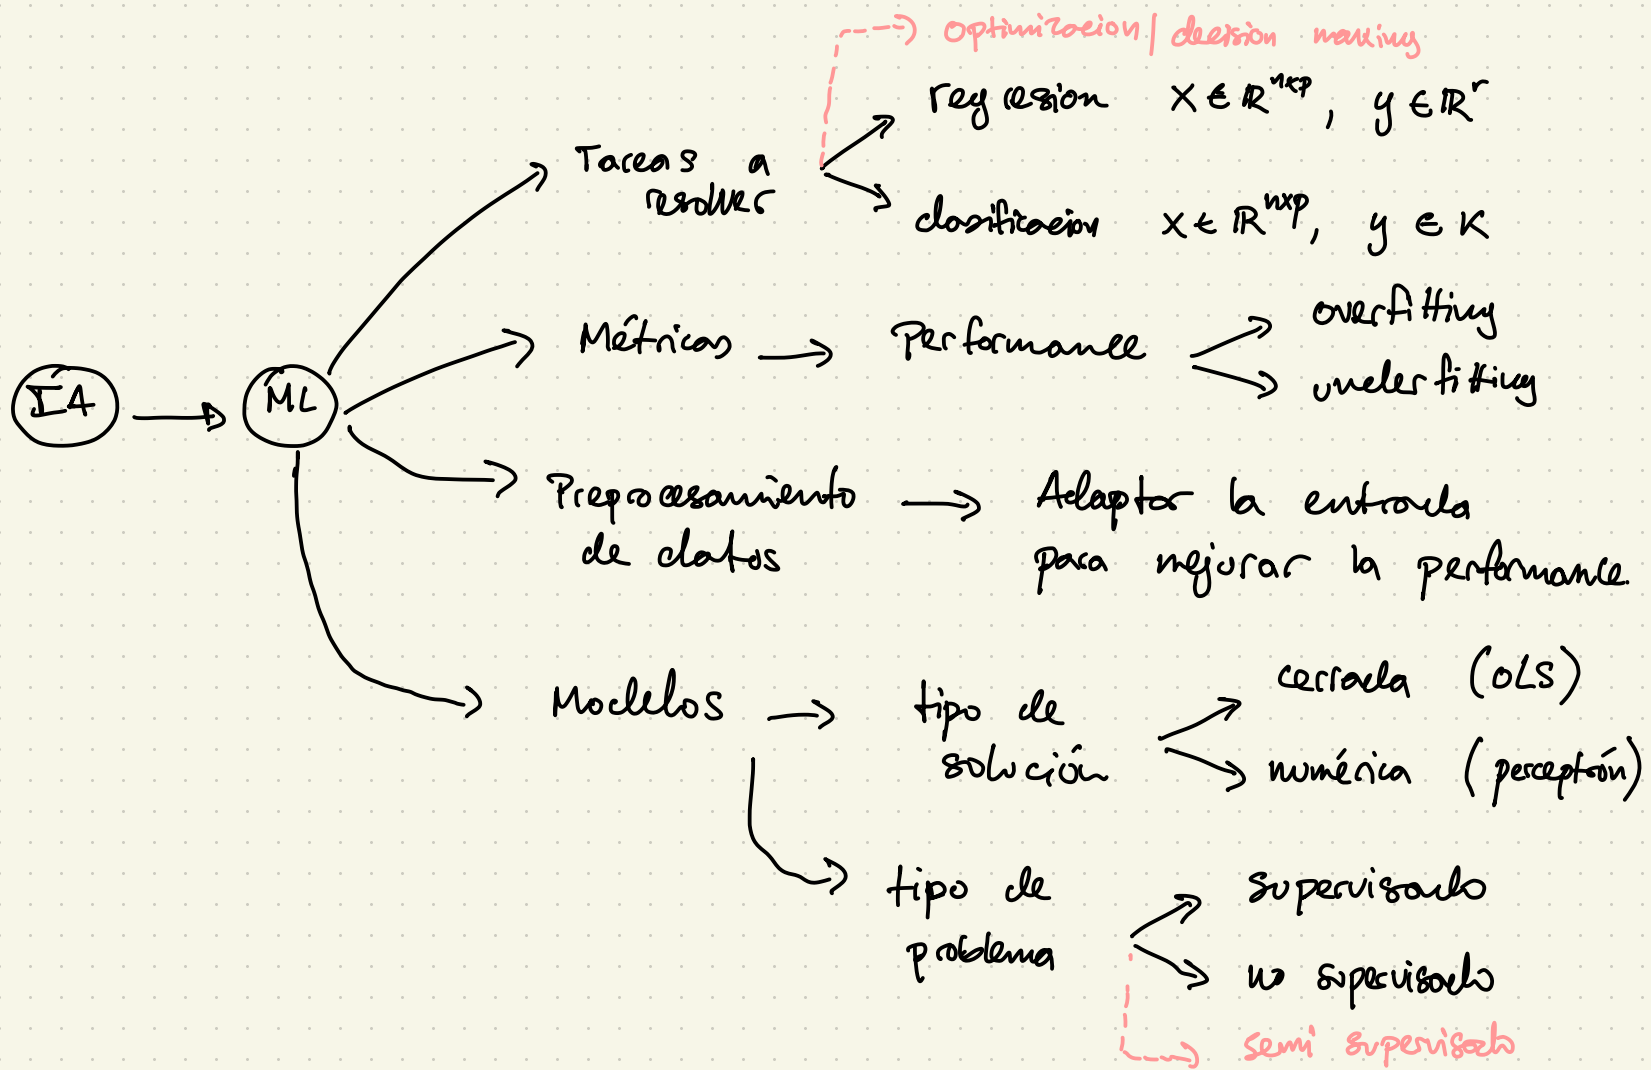
Introducción a la Inteligencia Artificial
Facultad de Ingeniería
Universidad de Buenos Aires



Clase 6

1. Clasificación Binaria
 - a. Motivación
 - b. Regresión Logística - Ejercicio de Aplicación
 - c. Regresión Logística - Teoría
2. Clasificación Multiclase
 - a. Motivación
 - b. Softmax
 - c. Ejercicio de Aplicación
3. Ejercicio integrador





Clasificación Binaria - Motivación

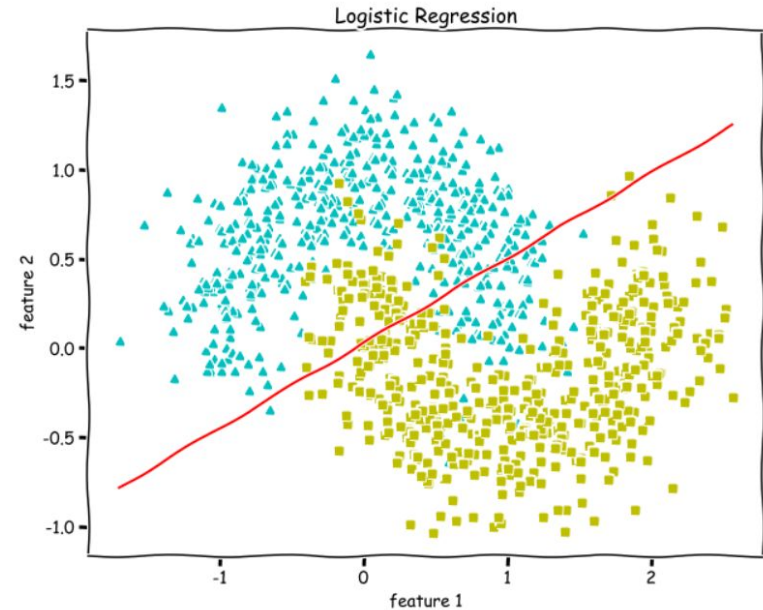
- Credit Card Fraudulent Transaction Detection
- Medical Diagnosis
- Spam Detection
- Sentiment Analysis
- Binary Image Classification

Clasificación: Dado un $\bar{X} \in \mathbb{R}^{n \times p}$ quiero mapear los x_{ij} a k clases (binario $k=2$).

Clases separables: $\forall x_{ij} \in y / y \in k \ D(y)=1$
cada input tiene una única clase \Rightarrow me dice que en el espacio de features existe una región (hiperplano, hiper región) que separa mis datos.

modelos lineales \rightarrow reg. logística,
SVM Lineal
LDA

modelos no lineales \rightarrow KNN, KSVM, CDA



Métricas

MSE (gato, perro) ? \rightarrow en clasif. usamos la **matriz de confusión**.

| real \ Pred | | ← prediction | |
|-------------|---|--------------|----|
| | | T | F |
| GL* | T | TP | FN |
| | F | FP | TN |

$$y = \mathbb{I}_{C=K} = \begin{cases} 1 & \text{si } y_i = K \\ 0 & \text{si } y_i \neq K \end{cases}$$

* GL: Golden Label
Ground truth
Real values

• Accuracy = $\frac{TP + TN}{\# \text{muestras}} \in [0, 1]$

• Specificity = $\frac{TN}{TN + FP}$
(TN rate)

• precision = $\frac{TP}{TP + FP}$

• recall = $\frac{TP}{P}$

• $F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{TP}{TP + \frac{1}{2}(FP + FN)}$

• $F_\beta = (1 + \beta)^2 \frac{\text{prec.} \cdot \text{recall}}{\beta^2 \text{prec} + \text{recall}} \quad (F_{0.25})$

Formas de clasificar:

+ Definimos un proceso de scoring \rightarrow como resolver la clasificación.

\uparrow complejidad $\Rightarrow \uparrow$ computo \Rightarrow mejor modelo
?

① Modelo generativo: modelamos la distrib de inputs y outputs \Rightarrow generamos la salida (permite samplear y generar data sintética) (GAN's)

② Modelos discriminantes: planteo $P(C_k | \bar{X})$ \rightarrow mediante inferencia bayesiana puedo obtener mi modelo.

③ Modelos de fn. discriminante: buscamos $f: \mathbb{R}^{n \times m} \mapsto [C_1, \dots, C_K]$

\hookrightarrow Regresión logística: la idea es partir del modelo de OLS:

partimos de $y \sim \beta(1, \pi_i) \Rightarrow E(y) = \pi_i, \text{Var}(y) = \pi_i(1 - \pi_i)$

me gustaría obtener algo como:

$$\pi_i = \bar{x}_i^t \bar{\beta}, \quad \bar{\beta} \in \mathbb{R}^{p \times 1}$$

$\pi_i \in [0, 1]$ pero $\bar{x}_i^t \bar{\beta}$ no lo hace \Rightarrow tengo que transformar el problema

$$f: [0, 1] \mapsto \mathbb{R}_{>0} \quad \mapsto \quad \text{odds}_i = \frac{\pi_i}{1 - \pi_i}$$

razón de probabilidad:


es el cociente entre la probabilidad del evento A y su complemento.

Vamos a tomar el log de la razón de probabilidad, esto es una transf. biyectiva $\mathbb{R}_{>0} \mapsto \mathbb{R}$. Esta transf. se la conoce como **logit** (log odds ratio):

$$\eta_i = \text{logit}(\pi_i) = \log\left(\frac{\pi_i}{1 - \pi_i}\right) = \bar{x}_i^t \bar{\beta}$$

$$\text{existe: } \pi_i = \text{antilogit}(\eta_i) = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

fn. sigmoide



Modelo de regresión logística




Sean y_1, \dots, y_n realizaciones de una binomial $y_i \sim \beta(1, \pi_i)$.

Assumimos la relación subyacente entre los datos x_i y el logit de la razón de probabilidad es lineal:

$$\text{logit}(\pi_i) = \beta_0 + \sum_{i=1}^p \beta_i \cdot x_i$$

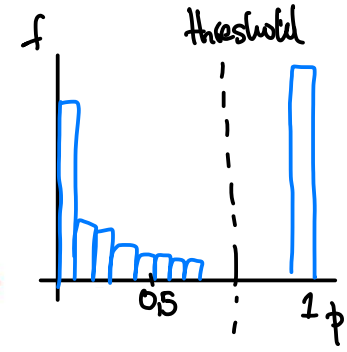
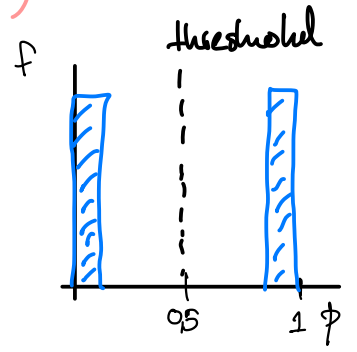


el modelo queda definido como un modelo lineal generalizado con resp. binomial y fn. de enlace logit.

Clasificación Binaria - Motivación

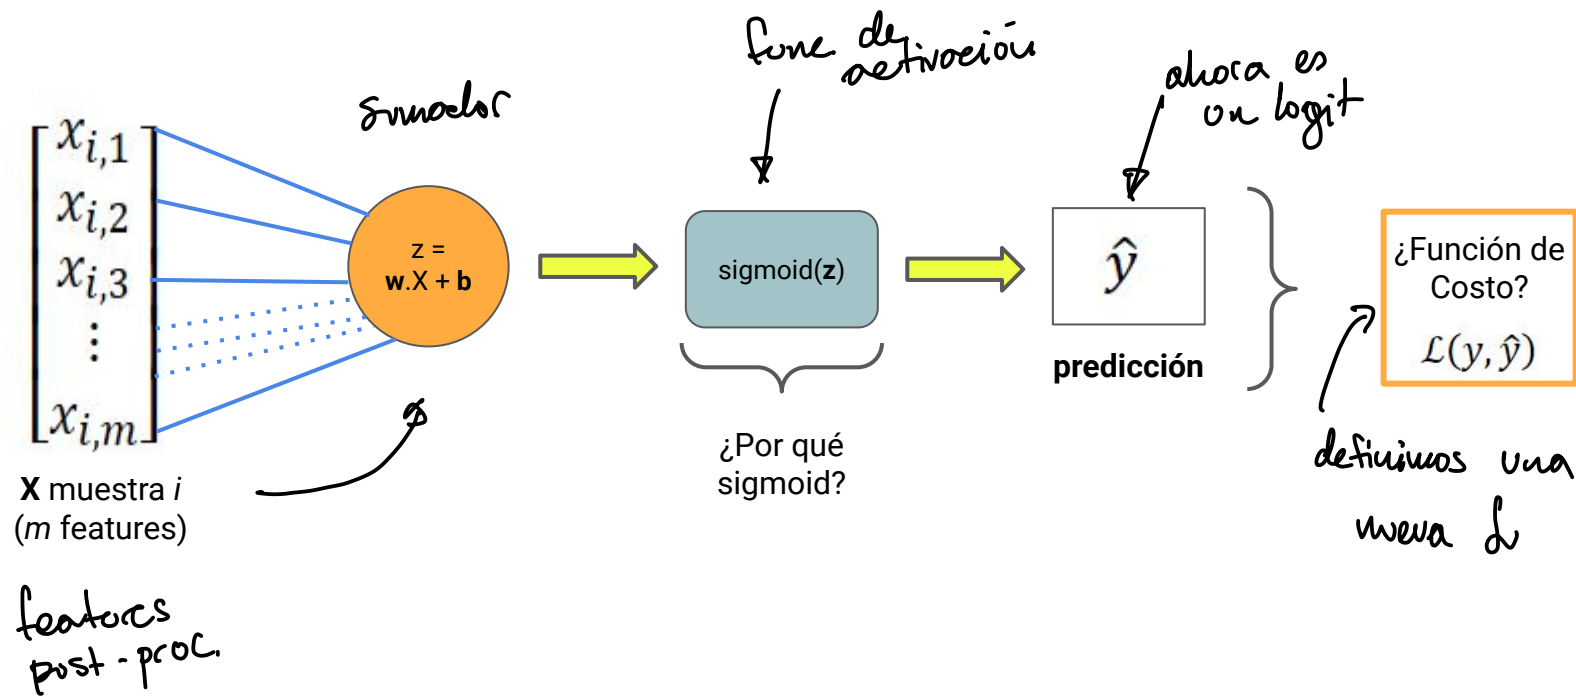


fn logística pertenece a la familia de fn. de Squeezing
f: $x, a \mapsto y$
 $\mathbb{R} \mapsto [0,1]$

$(x,y) \rightarrow \boxed{RLL} \rightarrow c, p(c)$



Regresión Logística



Quiero mapear $\sigma(a)$, partiendo de $z = w^t x$

$$\sigma(z) = \sigma(w^t x) \rightarrow \partial_a \sigma(a) = \sigma(a)(1 - \sigma(a)) \quad \text{propiedad}$$

$$\partial_w \sigma(z) = \sigma(w^t x) (1 - \sigma(w^t x)) x \quad (1)$$

planteamos la verosimilitud: $TP(y|x) = \prod_{i=1}^N \hat{y}_i^{y_i} (1 - \hat{y}_i)^{1-y_i} = L$

• N : cant. de muestras

• \hat{y} : predicción (prob)

• y : GL

$$\hat{y} = TP(c/x)$$

$$\log L = l$$

$$l = \sum_{i=1}^N \ln (TP_w(y_i = y_i | \bar{x}_i = x_i)) \rightarrow \text{buscamos maximizar } l.$$

$$\max_w \sum_{i=1}^N \ln (\sigma(w^t x)^{y_i} \cdot (1 - \sigma(w^t x))^{1-y_i})$$


$$\max_w \sum_{i=1}^N y_i \ln (\sigma(w^t x)) + (1 - y_i) \ln (1 - \sigma(w^t x)) \rightarrow x(-1)$$

$$\min_w \underbrace{\sum_{i=1}^N -y_i a - (1-y_i) b}_{(1)}$$

(1)

Vamos a aproximar (1) usando la *binary crossentropy*:




$$J(w) = \frac{1}{N} \cdot \sum_{i=1}^N [-y_i \odot - (1-y_i) \odot]$$








$$\bar{\nabla}_w J(w) = 0$$

$$\begin{aligned} \bar{\nabla}_w J(w) &\rightarrow \text{GD} \\ &\hookrightarrow \text{SGD} \\ &\hookrightarrow \text{GDB} \end{aligned}$$

Regresión Logística




Regresión Logística



Regresión Logística

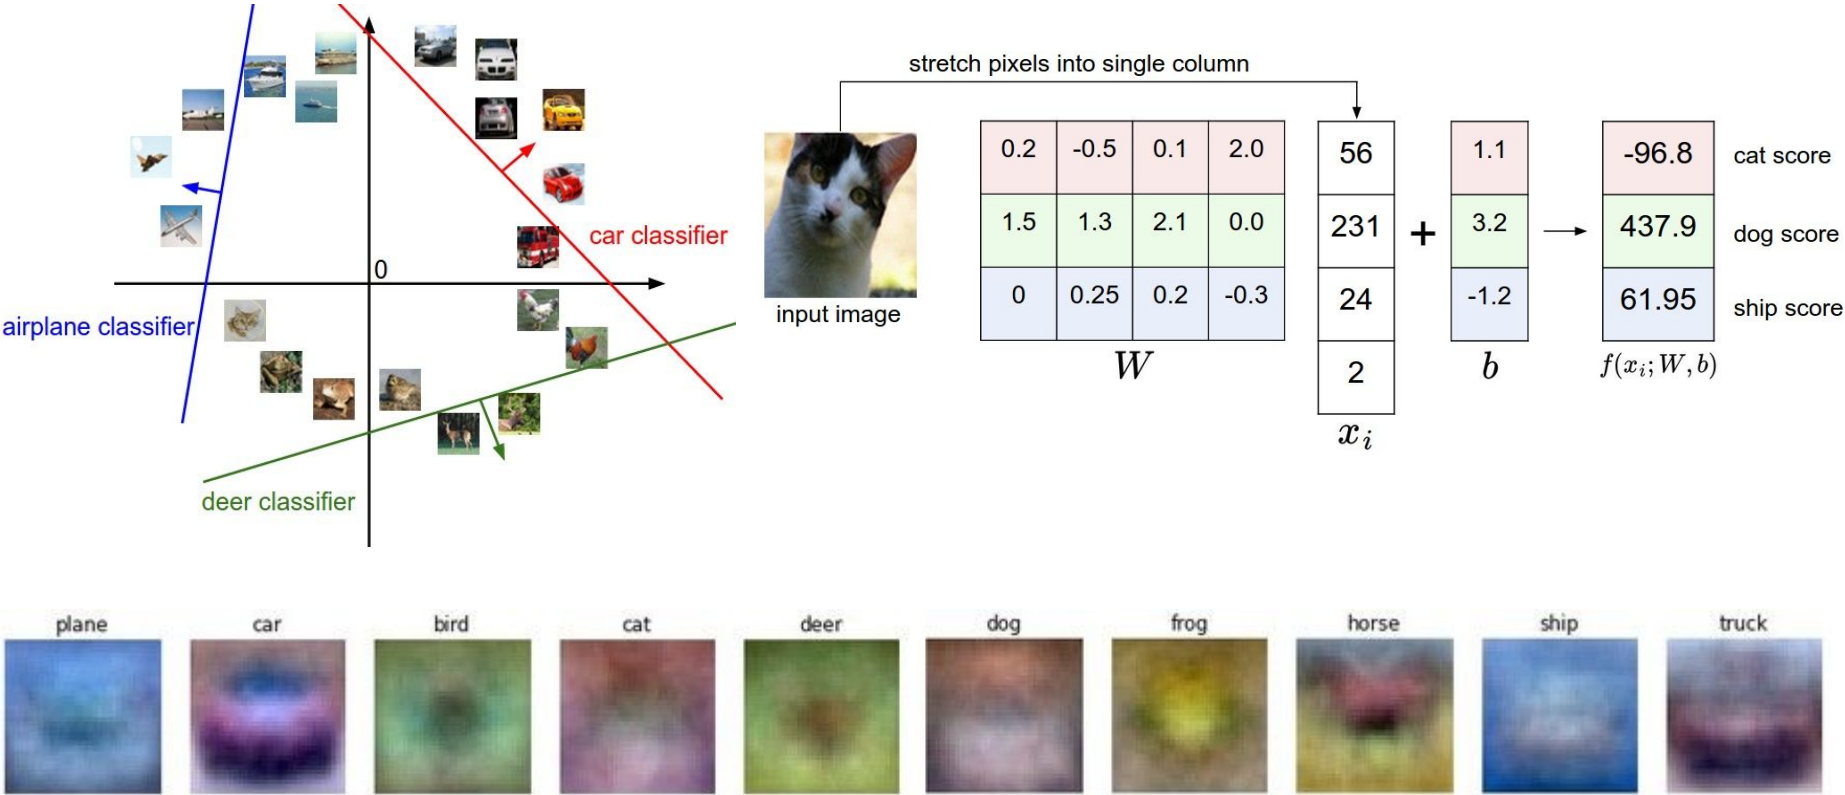
$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$



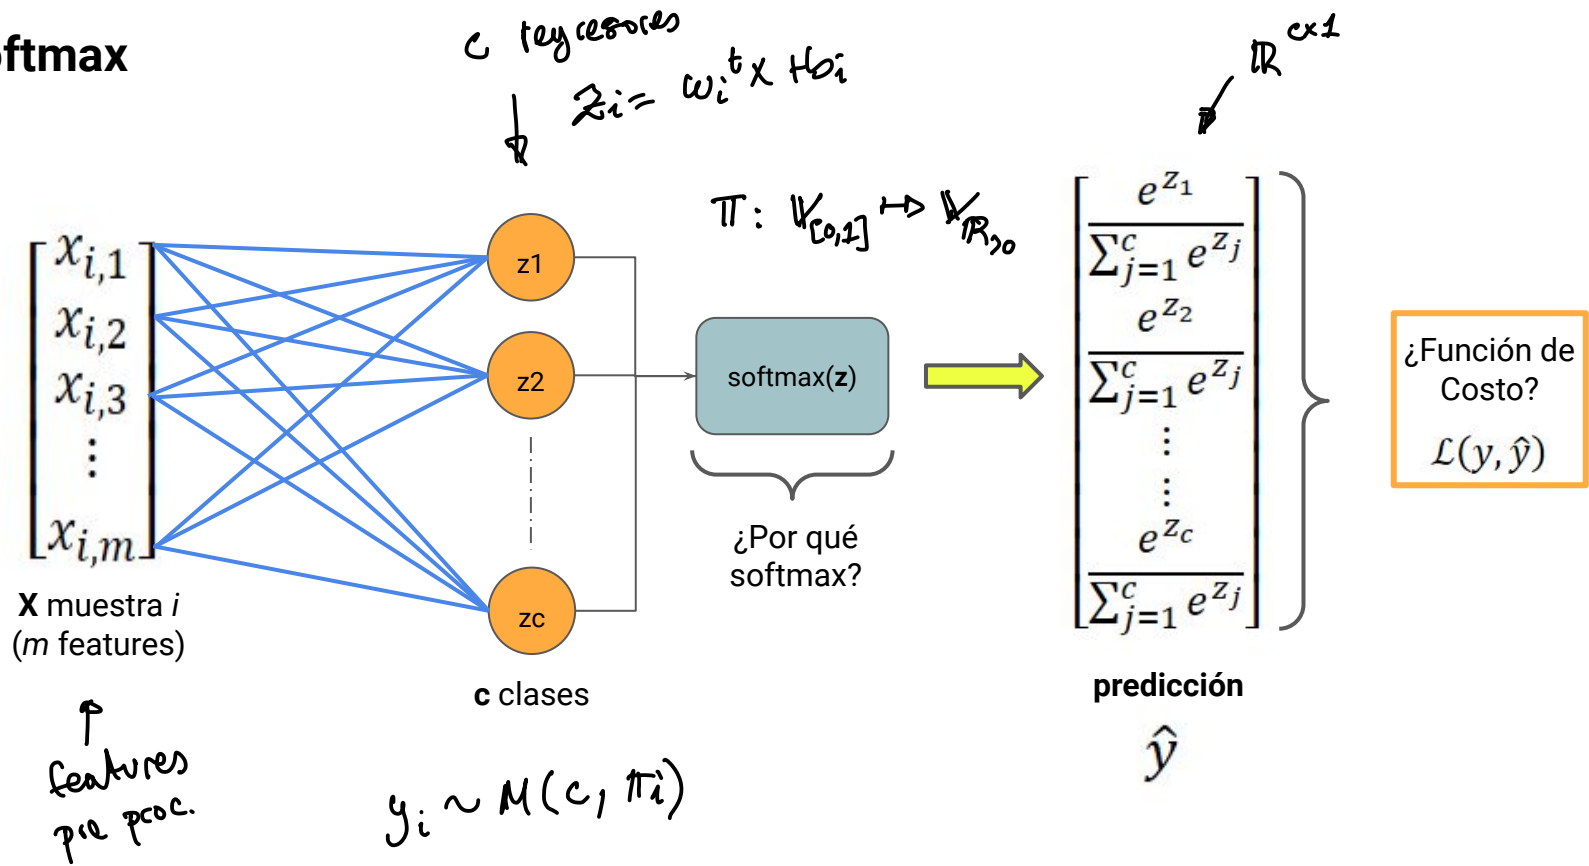
(1) REGRESIÓN LOGÍSTICA - EJERCICIO DE APLICACIÓN

(1) REGRESIÓN LOGÍSTICA - TEORÍA

Clasificación Multiclase - Motivación



Softmax



Softmax

$$\mathcal{P}(y_1 | x_i; w) = \frac{e^{w_1 x_i + b_1}}{\sum_j e^{z_j}}$$

$$f_{y_i} = z_i$$

$$P(y_i | x_i; W) = \frac{e^{f_{y_i}}}{\sum_j e^{f_j}}$$

$$\frac{e^{f_{y_i}}}{\sum_j e^{f_j}} = \frac{C e^{f_{y_i}}}{C \sum_j e^{f_j}} = \frac{e^{f_{y_i} + \log C}}{\sum_j e^{f_j + \log C}}$$

$q(x)$

$$H(p, q) = - \sum_x p(x) \log q(x)$$

1

[Softmax Forma Gráfica](#)

2

[Softmax Visualización 3D](#)

Softmax

Derivación Softmax

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

$$\frac{\partial p_i}{\partial z_k} = \frac{\partial \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}}{\partial z_k}$$

$$\frac{\partial p_i}{\partial z_k} = p_i(\delta_{ik} - p_k) \quad \delta_{ik} = \begin{cases} 1, i = k \\ 0, i \neq k \end{cases}$$

Derivación Cross-Entropy

$$\begin{aligned} L &= - \sum_i y_i \log(p_i) \\ \frac{\partial L}{\partial z_i} &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial z_i} \\ &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial p_j} \times \frac{\partial p_j}{\partial z_i} \\ &= - \sum_j y_j \frac{1}{p_j} \times \frac{\partial p_j}{\partial z_i} \end{aligned}$$

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= -y_i(1 - p_i) - \sum_{j \neq i} y_j \frac{1}{p_j} (-p_j \cdot p_i) \\ &= -y_i(1 - p_i) + \sum_{j \neq i} y_j \cdot p_i \\ &= p_i \left(y_i + \sum_{j \neq i} y_j \right) - y_i \end{aligned}$$

$$\frac{\partial L}{\partial z_i} = p_i - y_i$$

$$\frac{\partial z_i}{\partial W} = x_i$$

$$\frac{\partial L}{\partial W} = \sum_{i=1}^N (p_i - y_i) x_i$$

Usar gradiente descendente para actualizar W !!!

(1) SOFTMAX - EJERCICIO DE APLICACIÓN

Ejercicio integrador

1. Implementar el algoritmo de regresión logística en NumPy.
2. Aplicar el modelo a un dataset de elección.
3. Comparar los resultados con Scikit-Learn .
4. Comparar los resultados agregando regularización.

Bibliografía

- The Elements of Statistical Learning | Trevor Hastie | Springer
- An Introduction to Statistical Learning | Gareth James | Springer
- Deep Learning | Ian Goodfellow | <https://www.deeplearningbook.org/>
- Mathematics for Machine Learning | Deisenroth, Faisal, Ong
- Artificial Intelligence, A Modern Approach | Stuart J. Russell, Peter Norvig
- Understanding binary cross-entropy: a visual explanation | Daniel Godoy
- Visual Information Theory | [Link](#)
- <https://cs231n.github.io/>
- Classification and Loss Evaluation-Softmax and Cross Entropy Loss | Paras Dahal

