

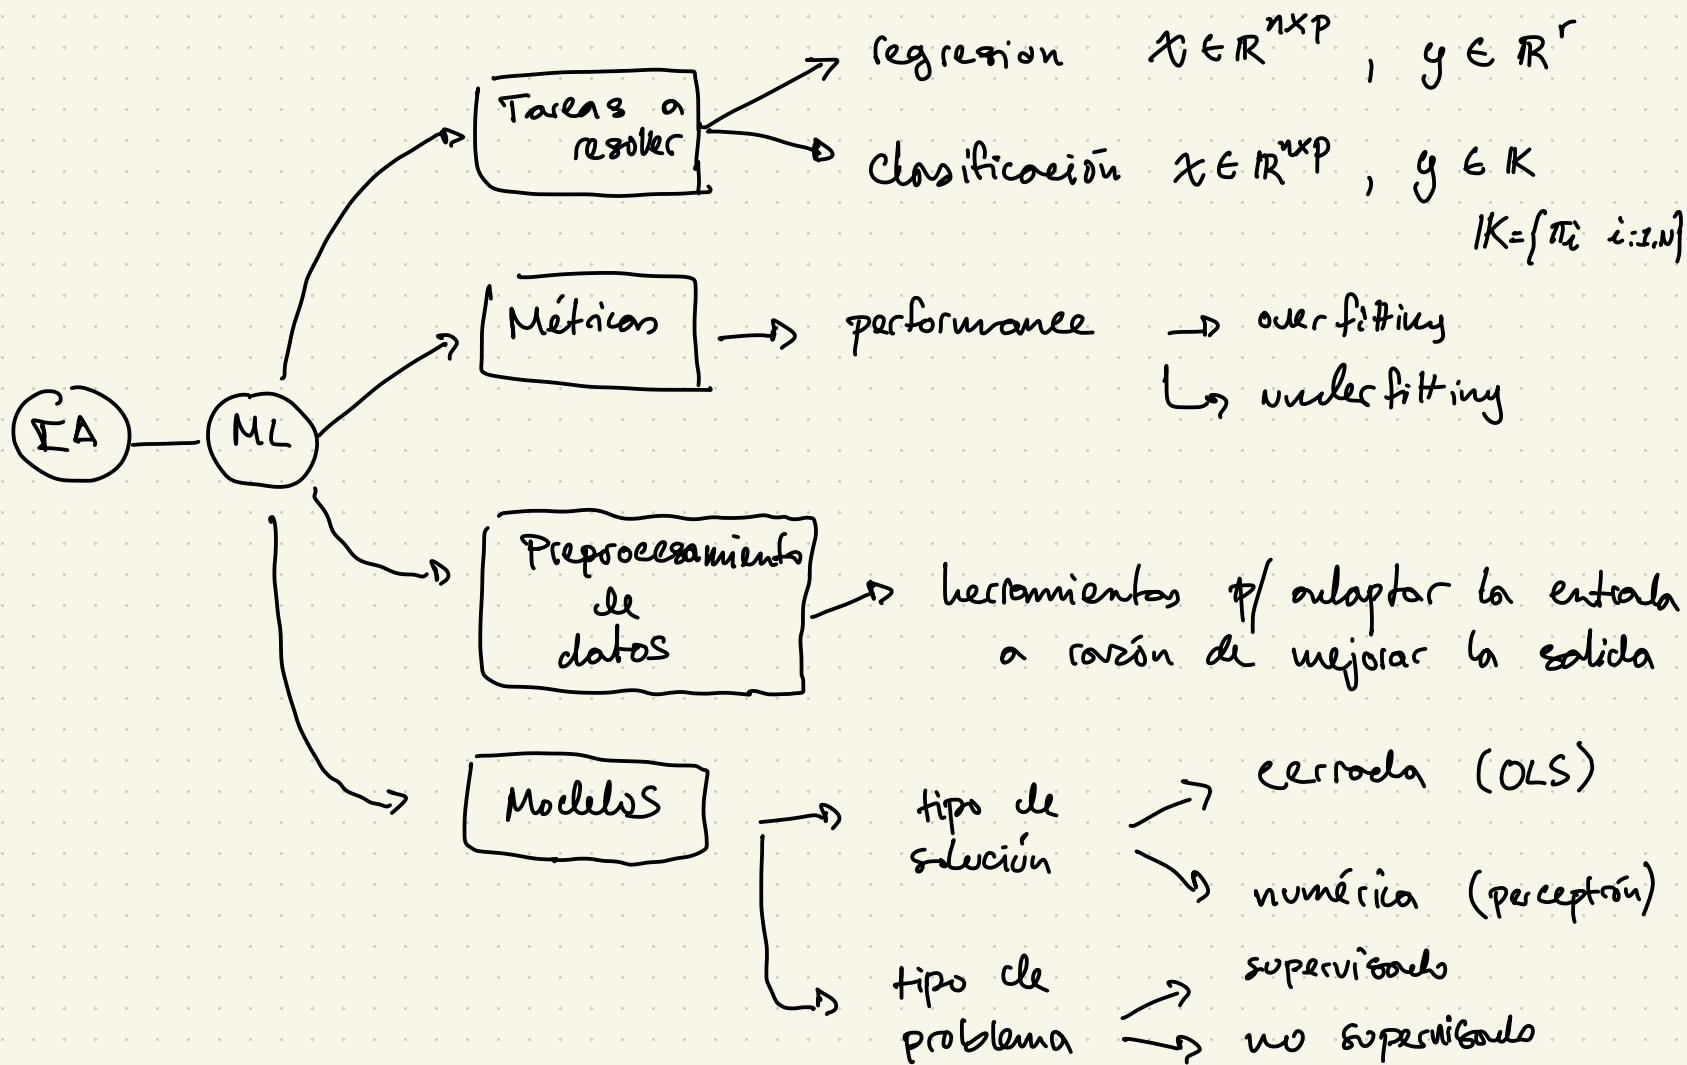
Introducción a la Inteligencia Artificial  
Facultad de Ingeniería  
Universidad de Buenos Aires



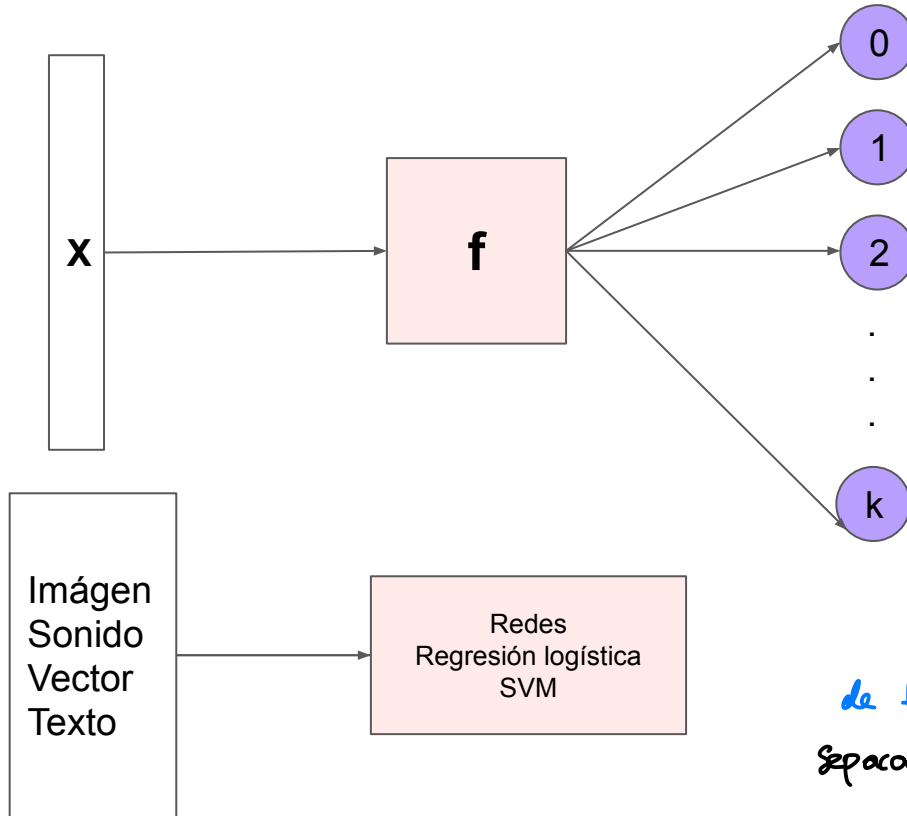
## Clase 6

1. Clasificación Binaria
  - a. Motivación
  - b. Regresión Logística - Ejercicio de Aplicación
  - c. Regresión Logística - Teoría
2. Clasificación Multiclase
  - a. Motivación
  - b. Softmax
  - c. Ejercicio de Aplicación
3. Ejercicio integrador





**Clasificación** Dado un  $X \in \mathcal{D} \subset \mathbb{R}^{n \times p}$  (un dataset de  $p$  features con  $n$  datos),  $X$  es la entrada e  $Y \in \mathcal{K}$  es la salida





$$f : \mathbb{R}^D \rightarrow \{0, 1, 2, \dots, k\}$$

Supuesto importante: las clases de  $Y$  son separables.

$$\forall x_{ij} \exists y_i / y_i \in \mathcal{K} \ f(y_i) \neq j$$

Esto nos dice que en el espacio de features  $\exists$  un hiperplano (región) que separa mis datos.

## Clasificación




## Clasificación binaria

$$f(x) = \begin{cases} 1 & \text{si } C_1 \\ 0 & \text{o.w.} \end{cases}$$

## Clasificación Binaria - Ejemplos

- Detección de fraudes
- Diagnóstico médico
- Detección de spam
- Sentiment Analysis
- Detección de objetos
- Outliers

*es fraude*  
*no es fraude*  
*pes*  
*neg*  
*spam*  
*non*  
*+*  
*-*  
*es obj1*  
*no es obj1*



## Clasificación Binaria - Diagnóstico médico

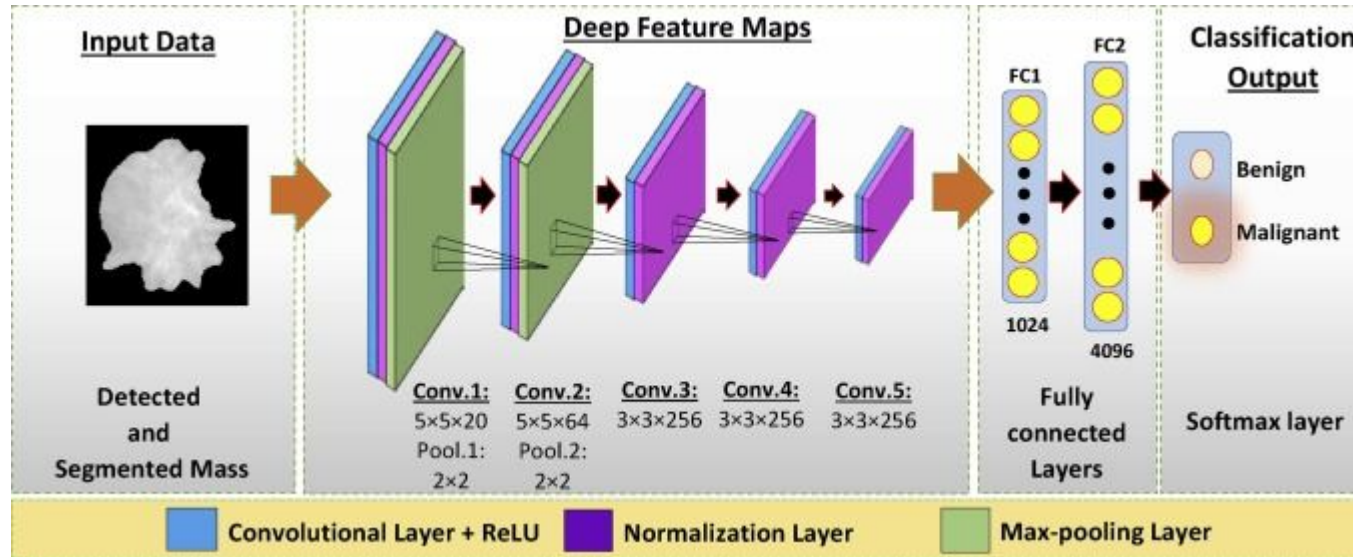


Imagen de: "A fully integrated computer-aided diagnosis system for digital X-ray mammograms via deep learning detection, segmentation, and classification"



## Clasificación Binaria - Spam detection

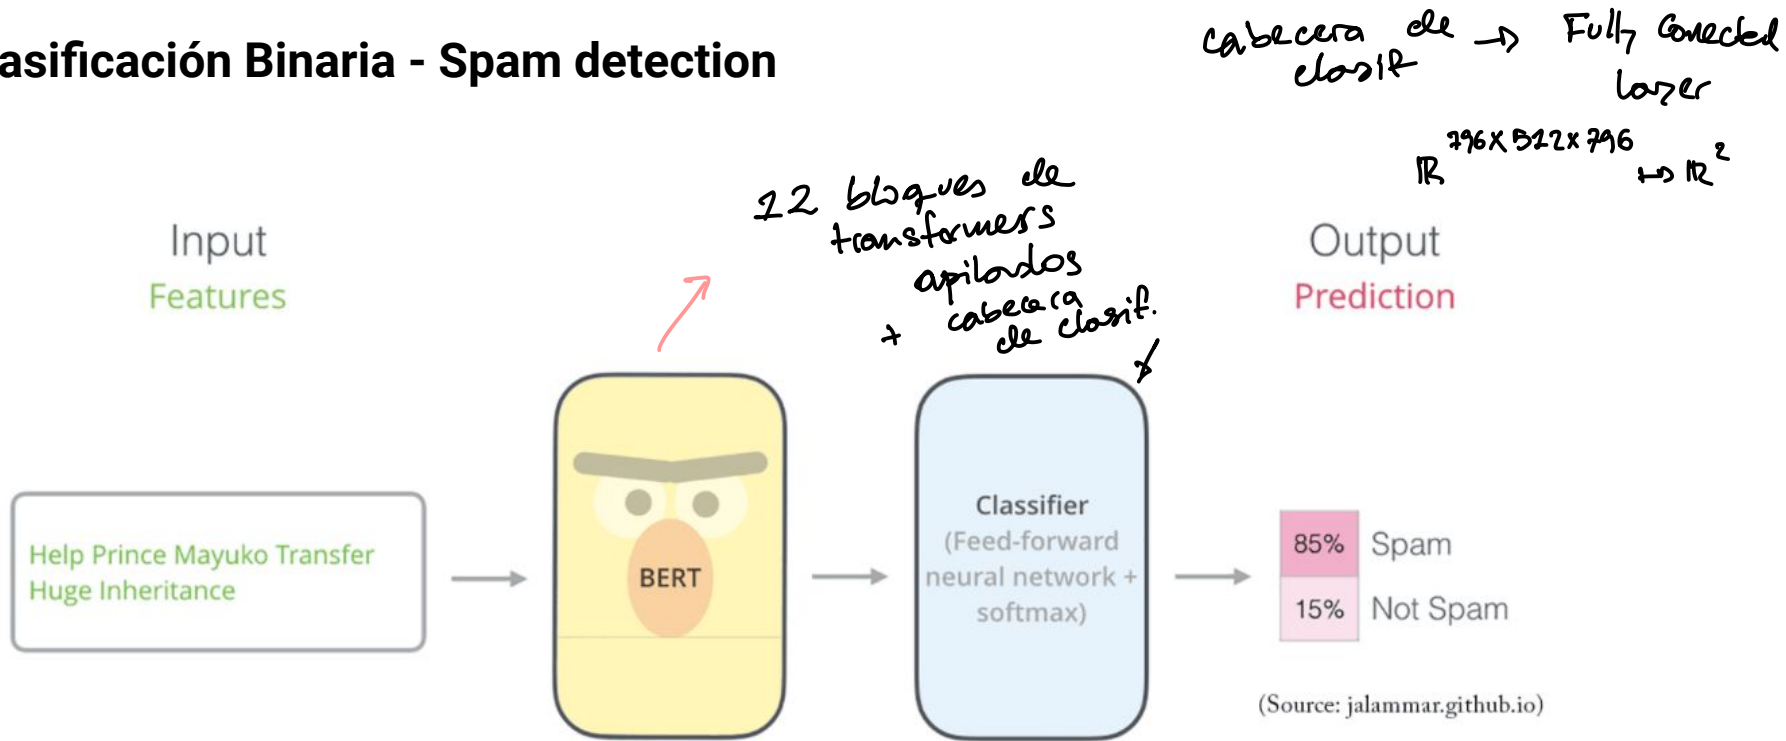
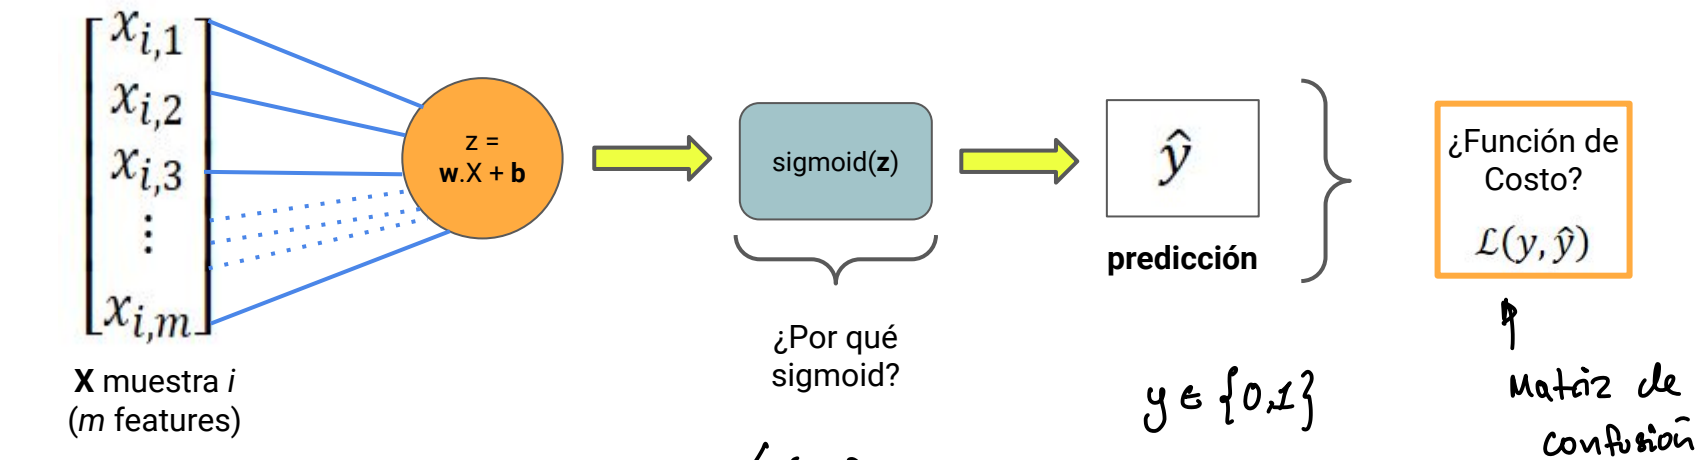


Imagen de: "Tutorial: Fine tuning BERT for Sentiment Analysis"

Regresión Logística → Extensión OLS p/ clasificación



$X_i \in \mathbb{R}^m$

$z \in \mathbb{R}$   
 $w \in \mathbb{R}^{m \times p}$   
 $b \in \mathbb{R}$

$\phi(z)$   
 $\phi: \mathbb{R} \mapsto [0, 1]$

Métricas de performance en clasificación binaria:

Como no podemos calcular MSE (se mueve, reposo) no construimos la matriz de confusión.

tengo  $y_{real}$ : Golden Label, Ground truth, True values

$y_{pred}$

	T	F	$y_{pred}$
T	TP	FN	
F	FP	TN	
$y_{real}$			

Accuracy:  $\frac{TP + TN}{\# \text{muestras}} \in [0, 1]$

Specificity: (TN rate)  $\frac{TN}{TN + FP}$

precision:  $\frac{TP}{TP + FP}$

recall:  $\frac{TP}{TP + FN}$

$F_1: 2 \frac{\text{prec.} \cdot \text{recall}}{\text{prec} + \text{recall}}$

## Formas de Clasificar

+ Definimos un proc de Scoring  $\Rightarrow$  cómo resolver la clasif.

$\uparrow$  complejidad  $\Rightarrow \uparrow$  computo  $\Rightarrow$  mejor modelo  
?

1. **Modelos generativos**: modelar las distrib de I/O  $\Rightarrow$  generar la salida (permite generar información sintética) (GAN's)

2. **Modelos discriminantes**: planteo  $P(C_k | \bar{X})$   $\Rightarrow$  mediante métodos de inferencia voy a estimar  $P$ .

3. **Modelos de fn. discriminante**: buscamos  $f: \mathbb{R}^{n \times m} \mapsto \{C_1, \dots, C_k\}$

$\hookrightarrow$  **Regresión logística**: (la idea es usar lo que sabemos de OLS).

parto de suponer  $y \sim \text{Bernoulli}(1, \pi_i) \Rightarrow E(y) = \pi_i, \text{Var}(y) = \pi_i(1 - \pi_i)$

me gustaria obtener algo como esto:

$$\pi_i = \bar{x}^t \cdot \bar{\beta} \quad ; \quad \bar{\beta} \in \mathbb{R}^{p \times 1}$$

$\pi_i \in [0, 1]$  , pero  $\bar{x}^t \bar{\beta}$  no lo hace  $\Rightarrow$  tengo que mapear el prob.

busco  $g: [0, 1] \mapsto \mathbb{R}_{>0} \rightsquigarrow \text{odds}_i = \frac{\pi_i}{1 - \pi_i}$

odds - razón de probabilidad  
es el cociente entre  $P(A)$  y  $P(\bar{A})$

Vamos a tomar el log de odds, con esto obtengo una función biyectiva

$\mathbb{R}_{>0} \mapsto \mathbb{R}$ . Esta transf. se llama **logit** (log odds ratio):

$$\eta_i = \text{logit}(\pi_i) = \bar{x}^t \cdot \bar{\beta}$$

existe **antilogit**:  $\pi_i = \text{antilogit}(\eta_i) = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$


sigmoid

## Logistic function

$$S(x) \in [0, 1]$$

$$\mathbb{R} \mapsto [0, 1]$$

$$S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1} = 1 - S(-x).$$



## Modelo de regresión Logística:


Sean  $y_1, \dots, y_n$  realizaciones de un proc Bernoulli  $(1, \pi_i)$ .

Asumimos que existe una relación **lineal** entre  $x_i$  (datos) y el **logit** de la razón de prob:


$$\text{logit}(\pi_i) = \beta_0 + \sum_{j=0}^p \beta_j x_{ij}$$

Este modelo queda definido como un **modelo lineal generalizado** con resp. binomial y fn. de enlace logit.


## Regresión Logística



Class-conditional -  $P(x|C_n)$



Posterior -  $P(C_n|x)$





¿Cómo obtengo  $p$ ?

quiero mapear  $\sigma(z) = \sigma(w^t x)$  (propiedad de  $\sigma$  da  $\sigma(a) = \sigma(a)(1 - \sigma(a))$ )

$$\partial_w \sigma(z) = \sigma(w^t x) (1 - \sigma(w^t x)) \quad (2)$$

planteamos la fun. de verosim.:  $P(y|x) = \prod_{i=1}^N \hat{y}_i^{y_i} (1 - \hat{y}_i)^{1-y_i} = L$

$N$ : cant muestras;  $\hat{y}$ : pred (prob)

$y$ : GL

$$\hookrightarrow \hat{y}_i = P(c/x) \quad \hookrightarrow l = \log L$$

$$l = \sum_{i=1}^N \ln (P_w(y_i = y_i | x_i = x_i)) \quad \leadsto \text{buscamos maximizar } l$$

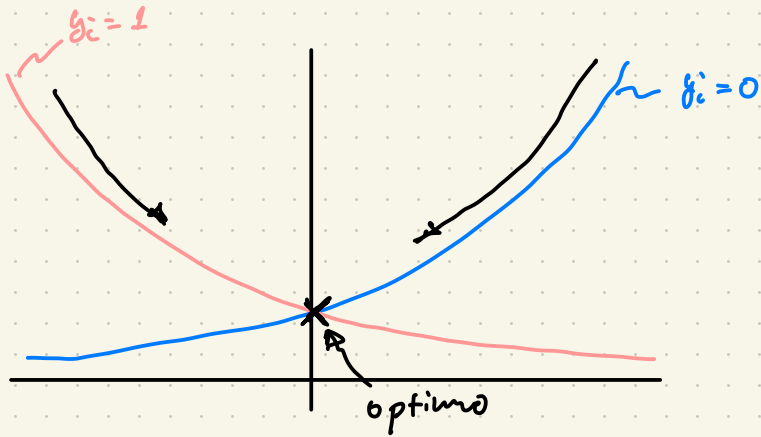
$$\max_w \sum_i \ln (\sigma(w^t x)^{y_i} \cdot (1 - \sigma(w^t x))^{1-y_i})$$

$$\max_w \sum_i y_i \underbrace{\ln(\sigma(w^t x))}_{(A)} + (1-y_i) \underbrace{\ln(1 - \sigma(w^t x))}_{(B)} \xrightarrow{x-1} \min_w \sum_i -y_i (A) - (1-y_i) (B)$$

mi  $\ell$  óptimo esta en  $\min_w \sum_i -y_i \textcircled{A} - (1-y_i) \textcircled{B}$

puedo encontrar el mínimo de  $\ell$  usando la **entropía binaria cruzada**  
(**binary crossentropy**):

$$\mathcal{J}(w) = \frac{1}{N} \sum_i -y_i \textcircled{A} - (1-y_i) \textcircled{B}$$



$$\nabla_w \mathcal{J} = 0$$



↳ GD

SGD

GD MB


## Función de costo - Binary cross entropy

$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$




## Función de costo - Binary cross entropy

$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$





## Regresión Logística








1: Verde, 0: Rojo

## Regresión Logística




## Regresión Logística



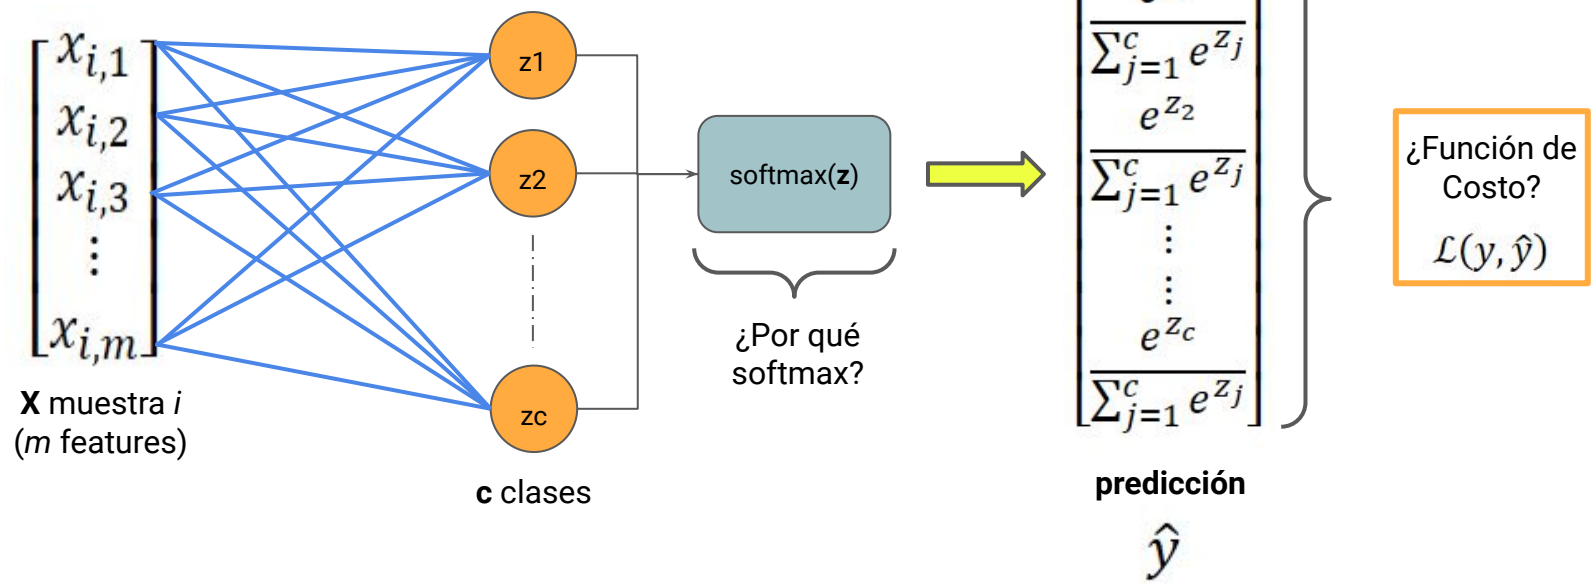
## Clasificación multiclase



## Clasificación Multiclase - Motivación



## Softmax



## Softmax

$$P(y_i | x_i; W) = \frac{e^{f_{y_i}}}{\sum_j e^{f_j}}$$

$$\frac{e^{f_{y_i}}}{\sum_j e^{f_j}} = \frac{C e^{f_{y_i}}}{C \sum_j e^{f_j}} = \frac{e^{f_{y_i} + \log C}}{\sum_j e^{f_j + \log C}}$$

$q(x)$

$$H(p, q) = - \sum_x p(x) \log q(x)$$

1

[Softmax Forma Gráfica](#)

2

[Softmax Visualización 3D](#)

## Softmax

### Derivación Softmax

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

$$\frac{\partial p_i}{\partial z_k} = \frac{\partial \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}}{\partial z_k}$$

$$\frac{\partial p_i}{\partial z_k} = p_i(\delta_{ik} - p_k) \quad \delta_{ik} = \begin{cases} 1, i = k \\ 0, i \neq k \end{cases}$$

Usar gradiente descendente para actualizar W !!!

### Derivación Cross-Entropy

$$\begin{aligned} L &= - \sum_i y_i \log(p_i) \\ \frac{\partial L}{\partial z_i} &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial z_i} \\ &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial p_j} \times \frac{\partial p_j}{\partial z_i} \\ &= - \sum_j y_j \frac{1}{p_j} \times \frac{\partial p_j}{\partial z_i} \end{aligned}$$

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= -y_i(1 - p_i) - \sum_{j \neq i} y_j \frac{1}{p_j} (-p_j \cdot p_i) \\ &= -y_i(1 - p_i) + \sum_{j \neq i} y_j \cdot p_i \\ &= p_i \left( y_i + \sum_{j \neq i} y_j \right) - y_i \end{aligned}$$

$$\frac{\partial L}{\partial z_i} = p_i - y_i$$

$$\frac{\partial z_i}{\partial W} = x_i$$

$$\frac{\partial L}{\partial W} = \sum_{i=1}^N (p_i - y_i) x_i$$



## Bibliografía

- The Elements of Statistical Learning | Trevor Hastie | Springer
- An Introduction to Statistical Learning | Gareth James | Springer
- Deep Learning | Ian Goodfellow | <https://www.deeplearningbook.org/>
- Mathematics for Machine Learning | Deisenroth, Faisal, Ong
- Artificial Intelligence, A Modern Approach | Stuart J. Russell, Peter Norvig
- Understanding binary cross-entropy: a visual explanation | Daniel Godoy
- Visual Information Theory | [Link](#)
- <https://cs231n.github.io/>
- Classification and Loss Evaluation-Softmax and Cross Entropy Loss | Paras Dahal